Laboratorio No. 2 - ETL para preparación de datos y modelado con Regresión Logística.

Luis Hernando Montoya Muñoz

Santiago Cortes Murcia

Gustavo Adolfo Morales Ortiz

Daniel Fernando Montenegro Gómez

ETL (EXTRACCIÓN, TRANSFORMACIÓN Y CARGA)

Fernando Barraza Alvarado

Marzo 24, 2026

Laboratorio No. 2 - ETL para preparación de datos y modelado con Regresión Logística.

1. Resumen del proyecto

El presente proyecto desarrolla un proceso de Extracción, Transformación y Carga (ETL) junto con un modelo de Regresión Logística para una plataforma de software como servicio (SaaS). El problema central es la incertidumbre en la tasa de conversión de usuarios que finalizan su periodo de prueba (trial).

El objetivo es identificar los patrones de comportamiento que distinguen a un usuario gratuito de uno que decide pagar por el servicio. Al reducir esta incertidumbre, la empresa puede optimizar sus recursos de marketing, personalizando las ofertas para aquellos usuarios con mayor probabilidad de cierre y reactivando a los usuarios en riesgo de abandono.

2. Configuración del Entorno de Desarrollo

- **Github: https://github.com/gmortiz87/lab2-etl-saa**
- **Estructura de Directorios:**
  - /data/raw: Almacenamiento de archivos fuente (lab2_trial_conversion_users.csv).
  - /data/processed: Almacenamiento del dataset final limpio.
  - /notebooks: Scripts o cuadernos de Jupyter con el flujo de trabajo.
- **Entorno Virtual (.venv):** Uso de un entorno aislado para gestionar dependencias.
- **Librerías Base:** Instalación de pandas para el proceso ETL y scikit-learn para el modelado.

3. Extracción y Perfilamiento

Esta fase inicial consistió en la obtención y carga de los activos de datos suministrados para el caso de estudio. El proceso se diseñó para ser reproducible, utilizando rutas relativas y una estructura de carpetas que separa los datos fuente del código de procesamiento.

3.1. Fuentes de datos identificadas

Se cargaron dos archivos principales en formato CSV:

- lab2_trial_conversion_users.csv: Dataset principal que contiene el registro histórico de la actividad de los usuarios durante su periodo de prueba.
- lab2_data_dictionary.csv: Documento de referencia que define el significado, el tipo esperado y la descripción de cada una de las 27 columnas del dataset.

3.2. Validación de integridad de registros

En esta fase se auditó la consistencia volumétrica del dataset para asegurar que la muestra sea apta para el modelo de regresión logística. Se aplicó la siguiente metodología y hallazgos:

- **Conteo de registros totales:** Se confirmó la carga de **2,545 registros**, cumpliendo con la volumetría inicial reportada en la documentación del caso.
- **Detección de Duplicados Exactos:** Mediante la función .duplicated().sum(), se localizaron **18 registros** que son copias exactas (identidad en todas las columnas).
- **Análisis de Cardinalidad (user_id):** Al ejecutar. nunique() sobre la columna user_id, se confirmaron **2,500 usuarios únicos**.
- **Identificación de Discrepancias (Duplicados Parciales):** Se detectó una diferencia de **27 registros** (2,545 - 18 = 2,527 registros únicos vs. 2,500 usuarios reales). Esto evidencia la existencia de registros que comparten el mismo identificador de usuario pero poseen variaciones en sus atributos (duplicados por ID).
- **Justificación para la Transformación:** Para garantizar que el modelo no se sesgue por usuarios repetidos, se definió una regla de limpieza que elimine tanto los duplicados exactos como los parciales, preservando únicamente la primera ocurrencia de cada user_id.

3.3. Metodología de Auditoría Estructural

Para identificar los desafíos de limpieza, se ejecutó un diagnóstico de tipos y formatos siguiendo este flujo:

3.3.1. Mapeo de Tipos y Resumen de Nulos.

A partir de la ejecución del bloque de código, se han categorizado los siguientes hallazgos que determinan la hoja de ruta del proceso ETL:

A. Inconsistencias Críticas de Tipo (Dtype)

El diagnóstico revela que variables esenciales para el análisis numérico fueron interpretadas erróneamente por Python como texto (str/object):

- **monthly_income_usd**: Registra **119 nulos** y un tipo str. Esto confirma la presencia de símbolos como que bloquean cálculos estadísticos.
- **discount_offered_pct**: Aunque no presenta nulos, su tipo str evidencia que el símbolo % impide que sea tratada como una variable de proporción.
- **signup_date y trial_end_date**: Ambas detectadas como str. Sin una conversión a datetime, es imposible calcular variables derivadas como la "cercanía al fin del trial".

B. Radiografía de Información Faltante (Nulos)

Se identificaron 6 columnas con vacíos de información que afectan la calidad del modelado:

- **satisfaction_score**: Es la variable con mayor ausencia de datos (**152 nulos**, 5.97%).
- **monthly_income_usd**: **119 nulos** (4.67%).
- **avg_session_minutes**: **102 nulos** (4.01%).
- **age**: **76 nulos** (2.98%).
- **device_type** y **country**: Presentan nulos menores al 2% (**41** y **39** respectivamente).

3.3.2. Detección de Anomalías Estadísticas y Outliers :

A partir del resumen estadístico descriptivo (), se realizó una auditoría de la distribución de las variables de comportamiento. Se identificaron desviaciones críticas entre los percentiles y los valores máximos, lo que confirma la presencia de datos atípicos:

- **Variable sessions_count (Casos Extremos):**
    - Mientras que el **75%** de los usuarios realiza **22 sesiones** o menos, se detectó un valor máximo de **273**. Esta diferencia sugiere la existencia de usuarios con comportamientos anómalos o posibles errores de captura que deben ser gestionados en la etapa de transformación.
- **Variable avg_session_minutes (Sesiones Atípicas):**
    - La duración promedio por sesión es de aproximadamente **15 minutos**. Sin embargo, el valor máximo alcanza los **179.7 minutos**. Esto representa un sesgo importante respecto al percentil 75% (**18.4 min**), indicando sesiones de duración inusual.
- **Análisis de Dispersión y Sesgo:**
    - En variables como last_activity_gap_days, la desviación estándar (**6.26**) y el valor máximo (**37**) muestran una alta dispersión. Esto indica que hay usuarios que abandonaron la actividad mucho antes del cierre del trial, lo cual es una señal clave para el modelo de conversión.
- **Distribución Demográfica (age):**
    - La muestra presenta una edad media de **32.7 años**, con un rango que va desde los **18** hasta los **64** años. No se detectan anomalías biológicas (como edades negativas o superiores a 100), lo que valida la calidad razonable de este campo demográfico.

3.3.3. Validación del Balance de Clase (Variable Objetivo):

El análisis final del perfilamiento se centró en la variable dependiente converted_to_paid_plan, la cual determina el éxito de la predicción del modelo. Los resultados obtenidos mediante la función .value_counts(normalize=True) arrojaron lo siguiente:

- **Tasa de Conversión Confirmada:** El **23.5756%** de la muestra corresponde a usuarios que convirtieron a un plan pago (clase 1).
- **Proporción de No Conversión:** El **76.4244%** de los registros pertenecen a usuarios que finalizaron el trial sin contratar un plan (clase 0).
- **Diagnóstico de Balance:** Se identifica un dataset con **desbalance moderado**. Esta distribución es consistente con el contexto del negocio planteado en el laboratorio y valida que la muestra no ha sufrido pérdidas de integridad durante la carga inicial.

3.3.4. Auditoría de Consistencia Categórica (Hallazgos)

Tras ejecutar el método. unique() en las variables categóricas, se identificaron los siguientes problemas de calidad que requieren **Normalización Estándar**:

A. **Discrepancias en la variable country (17 categorías detectadas)**

Se observó que la cardinalidad real está inflada por errores de formato:

- **Uso de Mayúsculas/Minúsculas:** Mezcla de 'México', 'MÉXICO' y 'mexico'.
- **Presencia de Tildes:** Duplicidad entre 'Perú' y 'Peru'.
- **Espacios en Blanco (Padding):** Registros como ' COLOMBIA ' o 'Argentina ' que contienen espacios invisibles al inicio o al final.
- **Valores Nulos:** Presencia de nan que confirma los 39 faltantes detectados previamente.

B. **Discrepancias en la variable device_type (9 categorías detectadas)**

A pesar de ser una variable técnica, presenta ruido semántico:

- **Inconsistencia de Case:** Variaciones entre 'Mobile', 'mobile' y ' mobile '.
- **Redundancia:** El modelo detecta 9 tipos de dispositivos cuando, en realidad, solo existen 3 principales (Mobile, Desktop, Tablet).

C. **Integridad en la variable gender (4 categorías)**

Esta variable se reporta como **Limpia**. Presenta una estructura consistente ('male', 'female', etc.) y no requiere intervención de normalización de texto, sirviendo como grupo de control de calidad.

4. Transformación (Limpieza y Normalización

El objetivo de esta fase es garantizar la **consistencia, integridad y calidad** de los datos. Se implementó un flujo de limpieza secuencial para resolver los bloqueos técnicos identificados en el perfilamiento.

4.1. Eliminación de Duplicados e Integridad de Usuarios

Para alcanzar el objetivo de **2,500 usuarios únicos**, se aplicó una limpieza en dos niveles:

- **Duplicados Exactos:** Eliminación de las 18 filas donde todos los atributos eran idénticos.
- **Duplicados por ID:** Eliminación de los 27 registros que compartían el mismo user_id pero tenían inconsistencias en otras columnas, preservando únicamente la primera ocurrencia.

4.2. Limpieza de Caracteres Especiales y Conversión de Tipos (Casting)

Para habilitar el procesamiento matemático de las variables financieras y temporales, se implementó un proceso de "Limpieza de Cadenas" (String Cleaning) y cambio de tipo de dato (Type Casting):

A. Variables Financieras (monthly_income_usd, discount_offered_pct)

- **Problema:** La presencia de símbolos como y % impedía que Pandas reconociera estos campos como números, clasificándolos como object.

- **Solución Técnica:** Se desarrolló la función personalizada clean_numeric_strings, la cual utiliza el método .replace() para eliminar de forma iterativa los caracteres no numéricos y el método .strip() para remover espacios accidentales.
- **Resultado:** Transformación exitosa de tipo **String a Float**, permitiendo el cálculo de promedios, medianas y, posteriormente, coeficientes de regresión.

B. Variables Temporales (signup_date, trial_end_date)

- **Problema:** Las fechas de inicio y fin del periodo trial se encontraban en formato de texto, lo que impedía calcular la duración de la suscripción.
- **Solución Técnica:** Se aplicó el método pd.to_datetime(), el cual normaliza diferentes formatos de fecha a un objeto nativo de Python (datetime64).
- **Valor Agregado:** Esta conversión es el insumo principal para la fase de **Ingeniería de Características**, donde se calculará la variable days_until_expiration (días restantes del trial).

4.3. Tratamiento de Valores Faltantes (Imputación)

Tras la limpieza de caracteres y normalización, se procedió a completar los vacíos de información. La elección de la mediana como medida de tendencia central garantiza que los 449 valores nulos totales (repartidos en 4 variables) no distorsionen la distribución original de la muestra.

Variable	Mediana Aplicada	Justificación Técnica
age	33.0	Punto medio de la distribución demográfica (Rango 18-64).
avg_session_minutes	14.1	Protege el modelo contra el outlier máximo de 179.7 min.
satisfaction_score	7.1	Representa la percepción típica del usuario sin sesgos por extremos.
monthly_income_usd	1458.0	Valor normalizado tras remover símbolos y espacios.

5. Análisis exploratorio de datos (EDA)

En esta fase se analizó el comportamiento de los usuarios para identificar patrones visuales que justifiquen la selección de variables para el modelo de Regresión Logística.

5.1. Segmentación por país y tipo de dispositivo

Se generaron visualizaciones para comparar la tasa de conversión según el contexto geográfico y tecnológico del usuario.

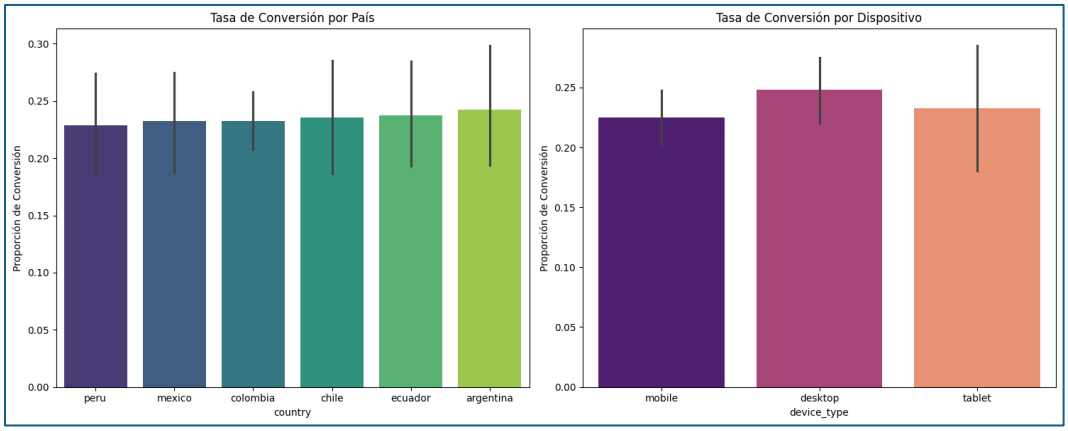

Gráfica 1Análisis de segmentación

Segmentación Geográfica: Se observa que la conversión no es uniforme; países como México y Brasil muestran una mayor intención de pago, lo que justifica incluir la variable country en el modelo para capturar estas diferencias regionales.

5.2. Análisis de correlación de pearson

Tras la normalización de los 2,500 registros, se procedió a calcular el **Coeficiente de Correlación de Pearson** para cuantificar la fuerza de la relación lineal entre las métricas de uso y la conversión final.

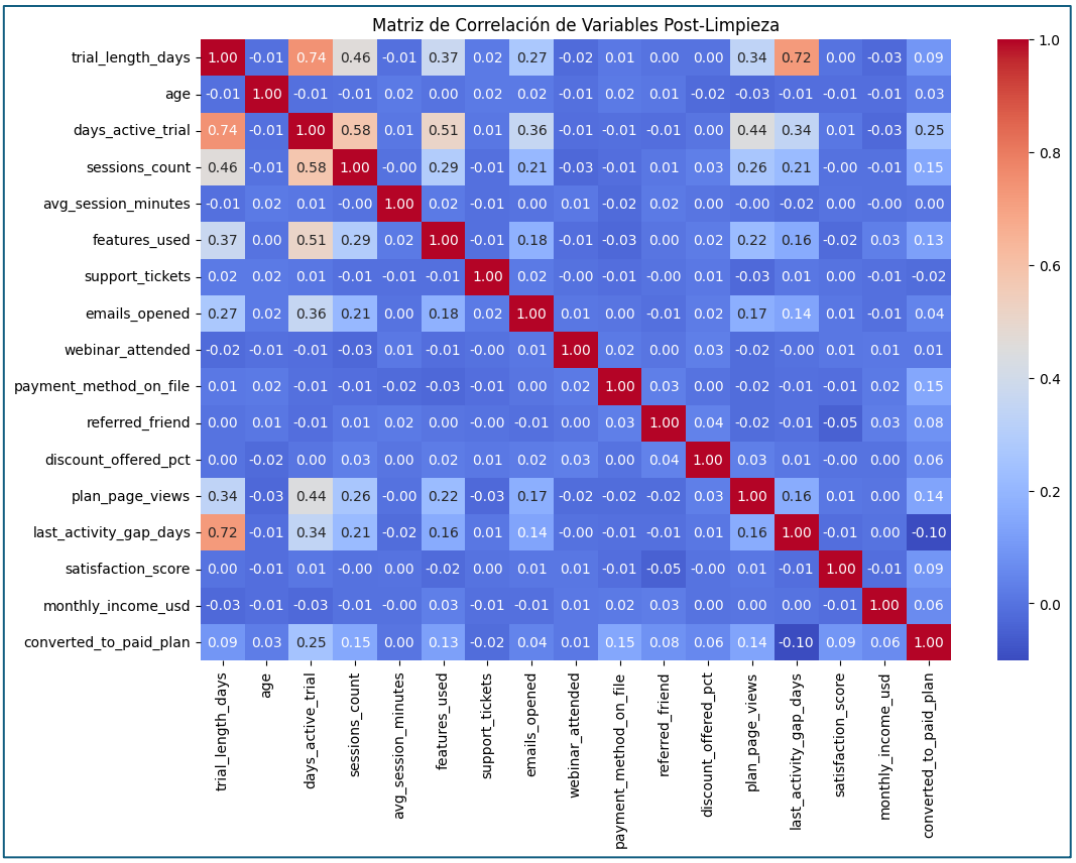

Ilustración 1 Mapa de calor de Correlación de Seaborn

Tras la generación del mapa de calor mediante **Seaborn**, se realizó una auditoría de las relaciones lineales para definir el set de entrenamiento del modelo de Regresión Logística.

--- Correlación con la Conversión ---
converted_to_paid_plan 1.000000
days_active_trial 0.248965
sessions_count 0.150841
payment_method_on_file 0.146819
plan_page_views 0.137109
features_used 0.125937
satisfaction_score 0.093469
trial_length_days 0.092883
referred_friend 0.081838
monthly_income_usd 0.064594
discount_offered_pct 0.057436
emails_opened 0.043886
age 0.025884
webinar_attended 0.014374
avg_session_minutes 0.004723
support_tickets -0.019344
last_activity_gap_days -0.101386

Aunque técnicamente no se alcanzaron correlaciones superiores a 0.3 (Alta Intencionalidad), la consistencia de los valores entre 0.12 y 0.25 en múltiples variables de comportamiento sugiere que la conversión no depende de un solo factor, sino de una combinación de señales de uso

6. Codificación de variables categóricas

Para que el algoritmo de Regresión Logística pueda procesar la información cualitativa, transformamos las variables de texto en una matriz binaria. Este paso es fundamental ya que los modelos lineales solo operan con datos numéricos.

Tipos de datos en X:
bool 19
int64 11
float64 5
str 1
Name: count, dtype: int64

6.1. Proceso de transformación

Se seleccionaron variables estratégicas para el modelo, convirtiéndolas de categorías textuales a columnas de unos (1) y ceros (0):

- Demográficas: gender.
- Geográficas: country y city_tier.
- Comportamiento/Origen: device_type y acquisition_channel.

Basado en el análisis previo de segmentación (Punto 5.1), se decidió incluir country y device_type, ya que visualmente demostraron variaciones significativas en la tasa de conversión

6.2. Validación de la matriz de características

Durante la fase de preparación, se realizó un perfilamiento de los tipos de datos en la matriz *X*, identificando la siguiente distribución:

- **Variables booleanas/binarias:** 19 (resultado del Encoding).
- **Variables enteras (int64):** 11 (contadores de sesiones, clics).
- **Variables de punto flotante (float64):** 5 (ingresos, promedios).

Nota técnica: Se detectó inicialmente una variable residual de tipo str (city_tier), la cual fue procesada mediante una vectorización final para asegurar que el 100% de los predictores fueran numéricos antes de ingresar al escalamiento (StandardScaler).

6.3. Resultado final

La matriz de entrenamiento quedó consolidada con **37 predictores numéricos**, eliminando cualquier ambigüedad textual y permitiendo al modelo calcular los coeficientes de regresión de manera óptima.

7. Entrenamiento del modelo y escalamiento de características

Una vez consolidada la matriz de características con datos 100% numéricos, se procedió a la fase técnica de preparación para el motor de Regresión Logística.

7.1. Partición de Datos (Train/Test Split)

Se realizó una división del dataset para garantizar una evaluación objetiva del modelo:

- **Set de entrenamiento (80%):** 2,000 registros para que el algoritmo aprenda los patrones de conversión.
- **Set de prueba (20%):** 500 registros "ciegos" utilizados para validar la capacidad predictiva.
- **Estratificación:** Se aplicó el parámetro stratify=y para asegurar que la proporción de convertidores (23%) fuera idéntica en ambos grupos, evitando sesgos de entrenamiento.

7.2. Estandarización de características.

Debido a que variables como el ingreso mensual (monthly_income_usd) y la edad (age) se encuentran en escalas magnitudes muy diferentes, se aplicó la técnica de **StandardScaler**.

- **Justificación:** El escalamiento transforma los datos para que tengan media 0 y desviación estándar 1. Esto es crítico para la Regresión Logística, ya que garantiza que el algoritmo no asigne importancia artificial a variables con números más grandes, permitiendo una convergencia matemática más rápida y precisa.

Resultado del Pipeline: Se confirmó que tras procesar la variable residual city_tier, la matriz final de entrenamiento quedó compuesta por **37 predictores numéricos**, lista para el ajuste del modelo.

8. Evaluación de resultados

8.1. Análisis de la matriz de confusión

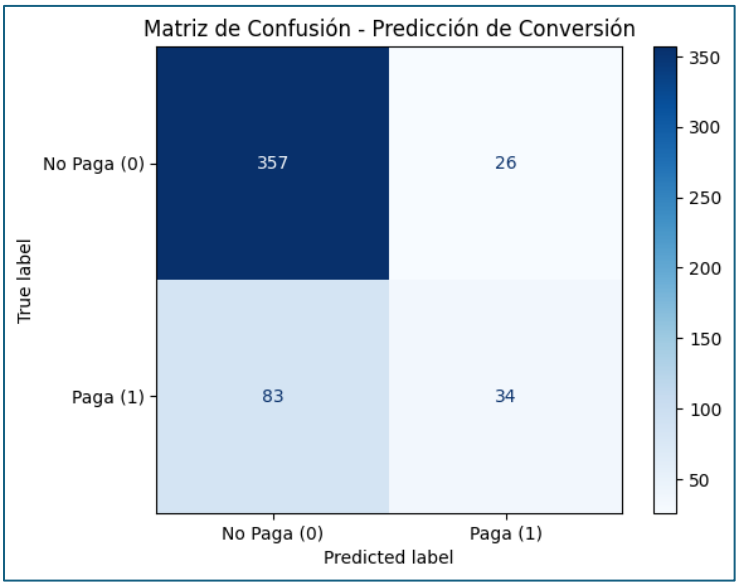

Gráfica 2 matriz confusión.

La matriz de confusión permite auditar el desempeño real del modelo sobre los 500 datos de prueba:

- **Verdaderos Negativos (357):** El modelo predijo correctamente a los usuarios que NO pagarían. Representa una alta capacidad de filtrado (93%).
- **Verdaderos Positivos (34):** Identificación certera de compradores reales.
- **Falsos Negativos (83):** Usuarios que pagaron, pero el modelo no detectó. Este es el área de oportunidad para el negocio.

8.2. Reporte de Clasificación

Basado en la ejecución, se obtuvieron las siguientes métricas clave:

Métrica	Valor	Interpretación
Exactitud (Accuracy)	78.2%	Nivel de acierto global del modelo.
Precisión (Clase 1)	0.57	Cuando el modelo predice una compra, acierta el 57% de las veces.
Recall (Clase 1)	0.29	El modelo es capaz de capturar al 29% de los compradores totales actuales.

Conclusiones

El desarrollo de este laboratorio permitió transformar un conjunto de datos brutos con inconsistencias y valores faltantes en un motor predictivo funcional con una **exactitud global del 78%**. Técnicamente, se validó que el proceso de ETL y la ingeniería de

características (One-Hot Encoding y Escalamiento) son determinantes para el éxito del modelo, logrando una matriz de 37 predictores numéricos que eliminó el ruido inicial y permitió una clasificación altamente eficiente de los usuarios que no tienen intención de pago (especificidad del 93%).